

Solución del Problema de Clasificación de Imágenes Climáticas con CNN

Joann Bedoya, Willian Correa, Alejandro Mesa, Jose Restrepo

Diciembre 10, 2024

1 Introducción

En este documento se presenta algunas soluciones técnicas al problema de clasificación de imágenes climáticas utilizando una red neuronal con CNN Convolutional Network, aplicada a un conjunto de datos meteorológicos descargado desde Kaggle. El dataset cuenta con imágenes categorizadas en distintas condiciones climáticas (dew, fogsmog, frost, entre otros.), lo cual requiere un modelo especializado para el procesamiento de imágenes. La solución fue implementada en Google Colab, utilizando la biblioteca Keras de TensorFlow.

1.1 Links

Colab: https://colab.research.google.com/drive/1qjz_uVWUzsTo_IPRWNAq5apIPtXxrHmA?usp=sharing

Github: https://github.com/OakEsteban/Proyecto_2_redes_neuronales_univalle.git

2 Objetivo

El objetivo principal es desarrollar un modelo CNN capaz de:

- Analizar imágenes meteorológicas, correctamente.
- Clasificarlas correctamente en sus respectivas categorías.
- Evaluar el rendimiento del modelo y proponer mejoras.

3 Metodología

El desarrollo del proyecto se dividió en las siguientes etapas:

3.1 Preparación de Datos

- Se utilizó el conjunto de datos de imágenes meteorológicas obtenido de Kaggle.
- Las imágenes se organizaron en carpetas por clase: lluvia, nieve, neblina, etc.
- Se aplicó preprocesamiento de imágenes usando la biblioteca `ImageDataGenerator` para normalización y aumento de datos.

3.2 Estructura del Modelo CNN

El modelo CNN diseñado consta de las siguientes capas:

1. **Capas Convolucionales:** Para la extracción de características.
2. **Capas de MaxPooling:** Para reducir la dimensionalidad.
3. **Capa Dense:** Para la clasificación final.
4. **Función de Activación Softmax:** Para obtener la probabilidad de cada clase.

El modelo se implementó utilizando la biblioteca TensorFlow/Keras.

3.3 Entrenamiento del Modelo

El modelo fue entrenado durante 15 épocas utilizando el optimizador Adam y la función de pérdida `categorical_crossentropy`.

Análisis de la Distribución

Se observa lo siguiente en la gráfica:

- La clase **rime** contiene el mayor número de imágenes, superando las 1,200 imágenes, lo que podría facilitar el aprendizaje del modelo para esta clase.
- Las clases como **rainbow** y **lightning** presentan un número significativamente menor de imágenes (alrededor de 200-400), lo cual puede dificultar la capacidad del modelo para aprender características representativas de estas clases.
- Otras clases como **fogsmog**, **dew**, y **sandstorm** tienen una cantidad moderada de imágenes, ubicándose entre 600 y 900 ejemplos.

Impacto en el Entrenamiento del Modelo

La distribución desigual de imágenes por clase introduce un **desbalance** en el conjunto de datos, lo que puede ocasionar:

- Mejor rendimiento en las clases con más imágenes debido a una mayor representación de características durante el entrenamiento.
- Peor rendimiento en las clases con menos imágenes debido a la falta de datos suficientes para generalizar correctamente.

3.4 Evaluación del Modelo

Para evaluar el rendimiento del modelo se utilizaron las siguientes métricas:

- **Precisión (Accuracy).**
- **Pérdida (Loss).**
- **Matriz de Confusión.**
- **Reporte de Clasificación (ROC, F1-Score).**

4 Resultados

4.1 Evolución de Precisión y Pérdida

En la Figura 1, se muestran las gráficas de evolución de la precisión y la pérdida durante el entrenamiento y la validación.




Figure 1: Evolución de precisión y pérdida.

5 Matriz de Confusión y Análisis de Resultados

En la Figura 2 se presenta la matriz de confusión generada para evaluar el rendimiento del modelo en la clasificación de las imágenes meteorológicas. Esta matriz muestra las predicciones del modelo frente a las clases reales.




Figure 2: Matriz de Confusión para la Clasificación de Imágenes Meteorológicas.

Análisis de la Matriz de Confusión

La matriz de confusión revela cómo se distribuyen las predicciones correctas e incorrectas entre las clases. A continuación, se describen algunos puntos clave:

- La diagonal principal representa las predicciones correctas del modelo, es decir, cuando la clase real coincide con la clase predicha. Por ejemplo:
 - La clase **fogsmog** presenta un alto número de predicciones correctas (105), lo que indica un buen rendimiento para esta clase.
 - La clase **rime** tiene 98 predicciones correctas, lo que refleja también un buen desempeño.
- Sin embargo, existen algunas confusiones significativas en otras clases:
 - La clase **frost** es confundida en 13 ocasiones con otras clases, especialmente con **glaze** (53 predicciones incorrectas).

- La clase **sandstorm** presenta un número relevante de errores, siendo confundida con **rime** y **snow**.
- La clase **rain** también muestra confusiones, con predicciones incorrectas hacia **glaze** y **hail**.
- Algunas clases como **rainbow** y **lightning** tienen predicciones más dispersas, lo que puede estar relacionado con la cantidad limitada de ejemplos en estas categorías.

Impacto de las Confusiones

El análisis de la matriz de confusión permite identificar las clases donde el modelo tiene dificultades, lo cual puede ser atribuido a:

- **Similitudes visuales** entre clases: Por ejemplo, las imágenes de **frost** y **glaze** pueden tener patrones similares.
- **Desbalance en los datos**: Clases con menos ejemplos como **rainbow** y **lightning** tienden a generar más errores debido a la falta de información suficiente para el aprendizaje.

5.1 Reporte de Clasificación

Se presenta un ejemplo del reporte de clasificación obtenido:

	precision	recall	f1-score	support
rain	0.85	0.90	0.87	100
snow	0.90	0.92	0.91	120
lightning	0.86	0.82	0.84	105

6 Curva ROC y Área Bajo la Curva (AUC)

La Figura 3 muestra la curva ROC (*Receiver Operating Characteristic*) para cada clase del conjunto de datos, junto con el área bajo la curva (AUC). Esta métrica evalúa la capacidad del modelo para discriminar entre las distintas clases.

Análisis de la Curva ROC

- Las curvas ROC cercanas a la esquina superior izquierda representan un buen desempeño del modelo.
- El área bajo la curva (AUC) para la mayoría de las clases supera el valor de 0.90, lo que indica una excelente capacidad del modelo para clasificar correctamente.
- La clase **lightning** obtuvo el mejor desempeño con un AUC de 0.99, mientras que la clase **glaze** tuvo el desempeño más bajo con un AUC de 0.85.




Figure 3: Curva ROC para cada clase con sus respectivos valores de AUC.

6.1 Curva ROC Micro-Promediada y AUC

La Figura 4 muestra la curva ROC micro-promediada. A diferencia de las curvas ROC por clase, la micro-promediada evalúa el desempeño global del modelo considerando todas las clases y calculando un promedio ponderado.

Análisis

- El área bajo la curva (AUC) micro-promediada es de **0.94**, lo cual indica un excelente rendimiento global del modelo.
- Esta métrica es útil cuando se necesita evaluar el desempeño global del modelo en problemas de clasificación multiclase.
- La curva micro-promediada se encuentra muy por encima de la línea diagonal (clasificación aleatoria), lo que confirma la capacidad del modelo para discriminar entre clases.

Importancia del Micro-Promedio

El micro-promedio es especialmente útil cuando el conjunto de datos presenta un desequilibrio entre clases, ya que considera cada muestra de manera individual y promedia los resultados de todas las clases.




Figure 4: Curva ROC Micro-Promediada con un AUC de 0.94.

7 Conclusiones

- Las capas convolucionales permiten extraer características relevantes de las imágenes.
- El aumento de datos mejora la capacidad de generalización del modelo.
- Algunas clases presentan mejores resultados que otras debido a la cantidad de datos disponibles.
- A pesar de haber hecho más épocas hasta las 30 de estas, la precisión no mejora significativamente desde la época 18.